**Πλατφόρμες και Αρχιτεκτονικές Νέφους**

**Εξαμηνιαία Εργασία**

**Μαυρουδή Ελένη inf2022113**

# Συγκριτική Αξιολόγηση Σχεσιακής και NoSQL Βάσης Δεδομένων με Χρήση Πραγματικών Δεδομένων Ταινιών

## Εισαγωγή

Η συνεχής αύξηση του όγκου των δεδομένων, η ποικιλία των μορφών τους και η ανάγκη για γρήγορη αναζήτηση και επεξεργασία έχουν οδηγήσει στην ανάπτυξη νέων προσεγγίσεων στη διαχείριση δεδομένων. Στο πλαίσιο αυτό οι παραδοσιακές σχεσιακές βάσεις δεδομένων εξακολουθούν να αποτελούν βασικό εργαλείο αποθήκευσης και ανάκτησης δομημένων δεδομένων ενώ παράλληλα έχουν αναπτυχθεί και μη σχεσιακά συστήματα (NoSQL databases) τα οποία δίνουν έμφαση στην ευελιξία του σχήματος, στην κλιμάκωση και στη διαχείριση μεγάλων ή ετερογενών συνόλων δεδομένων.

Η ανάγκη αυτή συνδέεται άμεσα με το σύγχρονο περιβάλλον των Big Data, όπου ο όγκος, η ταχύτητα παραγωγής, η ποικιλία και η αξιοπιστία των δεδομένων αποτελούν βασικές προκλήσεις για τα πληροφοριακά συστήματα.

Οι σχεσιακές βάσεις δεδομένων βασίζονται στην αποθήκευση των δεδομένων σε πίνακες με προκαθορισμένο σχήμα, εξασφαλίζοντας σαφή οργάνωση και υψηλό βαθμό συνέπειας. Αντίθετα οι NoSQL βάσεις δεν ακολουθούν υποχρεωτικά το παραδοσιακό σχεσιακό μοντέλο και συχνά υποστηρίζουν μια πιο ευέλικτη αναπαράσταση δεδομένων, χωρίς την ανάγκη αυστηρά προκαθορισμένου σχήματος, κάτι που τις καθιστά ιδιαίτερα χρήσιμες σε εφαρμογές μεγάλης κλίμακας ή σε περιπτώσεις όπου τα δεδομένα εξελίσσονται συνεχώς. Στη θεωρία των σύγχρονων βάσεων δεδομένων, η μετάβαση από τα παραδοσιακά συστήματα βάσεων δεδομένων που βασίζονται σε έναν μόνο εξυπηρετητή σε μη σχεσιακές αρχιτεκτονικές συνδέεται με τις αυξημένες απαιτήσεις των σύγχρονων διαδικτυακών εφαρμογών και των κατανεμημένων συστημάτων.

Στη συγκεκριμένη εργασία πραγματοποιείται η συγκριτική αξιολόγηση μίας σχεσιακής και μίας NoSQL βάσης δεδομένων πάνω στο ίδιο πραγματικό σύνολο δεδομένων ταινιών. Η σύγκριση γίνεται ως προς τη δομή αποθήκευσης, την ευκολία μοντελοποίησης, τη διατύπωση και εκτέλεση βασικών ερωτημάτων αναζήτησης, καθώς και ως προς τη βασική απόδοση των δύο προσεγγίσεων. Με τον τρόπο αυτό επιδιώκεται να αναδειχθούν στην πράξη οι διαφορές ανάμεσα στο σχεσιακό και στο μη σχεσιακό μοντέλο αλλά και να αξιολογηθεί ποια προσέγγιση είναι καταλληλότερη για δεδομένα του πραγματικού κόσμου με πολλαπλά χαρακτηριστικά και απαιτήσεις αναζήτησης.

**Σημείωση:** Το συνοδευτικό υλικό της εργασίας, που περιλαμβάνει τον κώδικα, βασικά αρχεία δεδομένων και τα αποτελέσματα των πειραματικών μετρήσεων, είναι διαθέσιμο στο αποθετήριο GitHub: https://github.com/EleniMavroudi/sqlite-vs-mongodb-imdb

## Περιγραφή του συνόλου δεδομένων και του πειραματικού πλαισίου

Για τις ανάγκες της παρούσας εργασίας επιλέχθηκε πραγματικό σύνολο δεδομένων από το IMDb το οποίο διατίθεται επίσημα για προσωπική και μη εμπορική χρήση. Τα δεδομένα του IMDb είναι διαθέσιμα σε μορφή gzipped TSV αρχείων, ενημερώνονται καθημερινά και περιλαμβάνουν πληροφορίες για τίτλους, αξιολογήσεις και πρόσωπα που σχετίζονται με οπτικοακουστικά έργα.

Στην εργασία δεν θα χρησιμοποιηθεί ολόκληρο το σύνολο των διαθέσιμων αρχείων, αλλά ένα συγκεκριμένο υποσύνολο, ώστε η μελέτη να παραμείνει στοχευμένη και διαχειρίσιμη. Πιο συγκεκριμένα, θα αξιοποιηθούν κυρίως τα αρχεία title.basics.tsv.gz και title.ratings.tsv.gz, καθώς και τα title.principals.tsv.gz, title.crew.tsv.gz και name.basics.tsv.gz για την ενσωμάτωση πληροφοριών σχετικά με τους βασικούς ηθοποιούς και τους σκηνοθέτες. Από το αρχείο title.basics θα χρησιμοποιηθούν πεδία όπως το μοναδικό αναγνωριστικό τίτλου (tconst), ο τύπος τίτλου (titleType), ο βασικός και ο πρωτότυπος τίτλος, η ένδειξη καταλληλότητας για ενήλικο κοινό (isAdult), το έτος κυκλοφορίας, η διάρκεια και τα είδη της ταινίας. Από το αρχείο title.ratings θα αξιοποιηθούν η μέση βαθμολογία και ο αριθμός ψήφων. Από το αρχείο title.principals θα αξιοποιηθούν πληροφορίες για τους βασικούς ηθοποιούς, ενώ από το αρχείο title.crew θα αξιοποιηθούν πληροφορίες για τους σκηνοθέτες των ταινιών.

Για λόγους ομοιογένειας και σαφήνειας, το σύνολο δεδομένων θα φιλτραριστεί ώστε να περιλαμβάνει μόνο εγγραφές με titleType = movie, δηλαδή μόνο κινηματογραφικές ταινίες. Με τον τρόπο αυτό αποφεύγεται η ανάμειξη διαφορετικών κατηγοριών τίτλων, όπως τηλεοπτικές

σειρές, επεισόδια ή βίντεο, και καθίσταται πιο αξιόπιστη η συγκριτική αξιολόγηση των δύο βάσεων δεδομένων.

Το πειραματικό πλαίσιο της εργασίας βασίζεται στη σύγκριση δύο διαφορετικών μοντέλων αποθήκευσης και διαχείρισης των ίδιων δεδομένων. Ως σχεσιακή βάση δεδομένων επιλέγεται η SQLite, ενώ ως NoSQL βάση δεδομένων επιλέγεται η MongoDB. Τα ίδια δεδομένα θα εισαχθούν και στα δύο συστήματα, ώστε η σύγκριση να είναι άμεση και δίκαιη. Η αξιολόγηση θα γίνει ως προς τη δομή αποθήκευσης, την ευκολία μοντελοποίησης, τη διατύπωση βασικών ερωτημάτων αναζήτησης και τη βασική απόδοση κατά την εκτέλεσή τους.

Τα βασικά ερωτήματα που θα χρησιμοποιηθούν στο πειραματικό μέρος της εργασίας θα αφορούν αναζητήσεις ταινιών ανά είδος, ανά έτος κυκλοφορίας και ανά εύρος βαθμολογίας, καθώς και συγκεντρωτικά ερωτήματα όπως το πλήθος ταινιών ανά είδος και ο μέσος όρος βαθμολογίας ανά είδος. Η ένταξη των βασικών ηθοποιών και των σκηνοθετών στο τελικό υποσύνολο δεδομένων επιτρέπει και την εκτέλεση πιο σύνθετων ερωτημάτων, όπως η αναζήτηση ταινιών συγκεκριμένου ηθοποιού, η αναζήτηση ταινιών συγκεκριμένου σκηνοθέτη και η σύγκριση βαθμολογιών με βάση τη συμμετοχή προσώπων ή τη σκηνοθετική παρουσία. Με αυτόν τον τρόπο, το επιλεγμένο σύνολο δεδομένων κρίνεται κατάλληλο για την ουσιαστική σύγκριση μίας σχεσιακής και μίας NoSQL βάσης δεδομένων σε συνθήκες πραγματικών δεδομένων.

## Θεωρία

### Σχεσιακές βάσεις δεδομένων

Οι σχεσιακές βάσεις δεδομένων αποτελούν ένα από τα πιο διαδεδομένα μοντέλα διαχείρισης δεδομένων και χρησιμοποιούνται εδώ και δεκαετίες σε εφαρμογές που απαιτούν οργανωμένη αποθήκευση και αξιόπιστη ανάκτηση πληροφορίας. Η βασική τους αρχή είναι η αποθήκευση των δεδομένων σε πίνακες, οι οποίοι αποτελούνται από γραμμές και στήλες, με κάθε πίνακα να αντιστοιχεί σε μια συγκεκριμένη κατηγορία οντοτήτων ή πληροφοριών. Το μοντέλο αυτό επιτρέπει τη δομημένη αναπαράσταση των δεδομένων και τη σαφή περιγραφή των χαρακτηριστικών τους.

Ένα βασικό χαρακτηριστικό των σχεσιακών βάσεων είναι το προκαθορισμένο σχήμα, δηλαδή ο σαφής ορισμός των πεδίων και του τύπου των δεδομένων πριν από την εισαγωγή τους στη βάση. Η προσέγγιση αυτή προσφέρει υψηλό βαθμό οργάνωσης και συνέπειας, καθώς τα

δεδομένα ακολουθούν συγκεκριμένους κανόνες και περιορισμούς. Για τον λόγο αυτό οι σχεσιακές βάσεις θεωρούνται ιδιαίτερα κατάλληλες σε περιπτώσεις όπου η ακρίβεια, η δομική σταθερότητα και η σαφής μοντελοποίηση των δεδομένων έχουν κεντρική σημασία.

Οι σχεσιακές βάσεις δεδομένων συνδέονται στενά με το παραδοσιακό μοντέλο RDBMS και με τη χρήση της SQL για την εκτέλεση ερωτημάτων, την αναζήτηση, την εισαγωγή και την ενημέρωση δεδομένων. Σε αυτό το πλαίσιο η πληροφορία οργανώνεται σε επιμέρους πίνακες και η συσχέτιση ανάμεσά τους γίνεται μέσω κατάλληλων πεδίων. Η λογική αυτή προσφέρει σαφήνεια και δομή αλλά μπορεί να οδηγήσει σε αυξημένη πολυπλοκότητα όταν απαιτούνται πιο σύνθετες αναζητήσεις σε μεγάλα ή συνεχώς μεταβαλλόμενα σύνολα δεδομένων. Στη σχετική θεωρία τονίζεται ότι τα παραδοσιακά συστήματα βάσεων δεδομένων που βασίζονταν σε έναν μόνο κόμβο έφτασαν σε όρια κλιμάκωσης σε σύγχρονες διαδικτυακές εφαρμογές, γεγονός που συνέβαλε στην ανάπτυξη εναλλακτικών μη σχεσιακών αρχιτεκτονικών.

Παρά τους περιορισμούς τους σε ορισμένα περιβάλλοντα μεγάλης κλίμακας, οι σχεσιακές βάσεις παραμένουν εξαιρετικά σημαντικές, καθώς προσφέρουν σταθερότητα, ωριμότητα και σαφή λογική οργάνωσης. Η σχεσιακή προσέγγιση θα εκπροσωπηθεί από τη βάση SQLite η οποία επιλέχθηκε επειδή είναι απλή στη χρήση, ευρέως διαδεδομένη και κατάλληλη για πειραματική υλοποίηση και σύγκριση με μία NoSQL βάση δεδομένων.

**NoSQL βάσεις δεδομένων**

Οι NoSQL βάσεις δεδομένων αποτελούν μια κατηγορία μη σχεσιακών συστημάτων διαχείρισης δεδομένων τα οποία αναπτύχθηκαν για να καλύψουν ανάγκες που δεν εξυπηρετούνται πάντα αποτελεσματικά από το παραδοσιακό σχεσιακό μοντέλο. Ο όρος NoSQL χρησιμοποιείται για βάσεις που δεν βασίζονται κυρίως στη λογική των πινάκων και του αυστηρά προκαθορισμένου σχήματος, ενώ συχνά δίνουν έμφαση στην επεκτασιμότητα, την ευελιξία και τη διαχείριση μεγάλου όγκου δεδομένων.

Η εμφάνιση των NoSQL βάσεων συνδέεται με την ανάπτυξη σύγχρονων διαδικτυακών εφαρμογών μεγάλης κλίμακας, όπου οι απαιτήσεις για ταχύτητα, διαθεσιμότητα και κλιμάκωση έγιναν ιδιαίτερα αυξημένες. Στη σχετική βιβλιογραφία αναφέρεται ότι τα παραδοσιακά RDBMS παρουσίασαν περιορισμούς κυρίως ως προς την οριζόντια κλιμάκωση, την παράλληλη επεξεργασία και το κόστος διαχείρισης σε περιβάλλοντα web-scale. Για τον λόγο αυτό

αναπτύχθηκαν μη σχεσιακές προσεγγίσεις, οι οποίες επιχειρούν να αντιμετωπίσουν αποτελεσματικότερα τέτοιου είδους απαιτήσεις.

Ένα από τα βασικά χαρακτηριστικά των NoSQL βάσεων είναι ότι συχνά υποστηρίζουν πιο ευέλικτη αναπαράσταση δεδομένων, χωρίς αυστηρά προκαθορισμένο σχήμα. Αυτό σημαίνει ότι η δομή των δεδομένων μπορεί να προσαρμόζεται ευκολότερα στις ανάγκες της εφαρμογής και να μεταβάλλεται με μικρότερη δυσκολία σε σχέση με ένα αυστηρά σχεδιασμένο σχεσιακό μοντέλο. Η ιδιότητα αυτή είναι ιδιαίτερα χρήσιμη όταν τα δεδομένα είναι μερικώς δομημένα, ετερογενή ή μεταβάλλονται συχνά με την πάροδο του χρόνου.

Οι NoSQL βάσεις δεν αποτελούν ένα ενιαίο μοντέλο, αλλά περιλαμβάνουν διαφορετικές κατηγορίες, όπως key-value stores, βάσεις εγγράφων, column-oriented βάσεις και graph databases. Στην παρούσα εργασία μας ενδιαφέρει κυρίως η κατηγορία των βάσεων εγγράφων, καθώς η MongoDB αποθηκεύει τα δεδομένα σε έγγραφα τύπου JSON/BSON, επιτρέποντας την ομαδοποίηση πολλών σχετικών χαρακτηριστικών στο ίδιο αντικείμενο. Η προσέγγιση αυτή είναι συχνά πιο φυσική για δεδομένα που έχουν πολλά περιγραφικά πεδία, όπως τα δεδομένα ταινιών που χρησιμοποιούνται στη συγκεκριμένη μελέτη.

Παρά τα σημαντικά πλεονεκτήματά τους, οι NoSQL βάσεις δεν αποτελούν καθολική λύση για κάθε πρόβλημα. Στη βιβλιογραφία επισημαίνεται ότι οι NoSQL βάσεις δεδομένων είναι ιδιαίτερα κατάλληλες σε περιβάλλοντα όπου βασική προτεραιότητα αποτελούν η κλιμάκωση, η ευελιξία στη διαχείριση των δεδομένων και η υψηλή διαθεσιμότητα του συστήματος. Αυτό συμβαίνει επειδή έχουν σχεδιαστεί ώστε να ανταποκρίνονται καλύτερα σε εφαρμογές μεγάλης κλίμακας, στις οποίες ο όγκος των δεδομένων αυξάνεται συνεχώς και οι απαιτήσεις πρόσβασης είναι αυξημένες. Παρ' όλα αυτά, οι NoSQL βάσεις δεν αποτελούν την καταλληλότερη λύση σε κάθε περίπτωση. Σε εφαρμογές όπου απαιτείται αυστηρή συνέπεια των δεδομένων και αξιόπιστη υποστήριξη συναλλαγών, οι σχεσιακές βάσεις δεδομένων εξακολουθούν να αποτελούν πιο ασφαλή και κατάλληλη επιλογή. Επομένως, η επιλογή ανάμεσα στο σχεσιακό και στο NoSQL μοντέλο δεν είναι απόλυτη, αλλά εξαρτάται από τη φύση των δεδομένων και από τις απαιτήσεις της κάθε εφαρμογής.

**Σύγκριση σχεσιακού και NoSQL μοντέλου**

Οι σχεσιακές και οι NoSQL βάσεις δεδομένων αποτελούν δύο διαφορετικές προσεγγίσεις στη διαχείριση δεδομένων, καθεμία από τις οποίες εξυπηρετεί διαφορετικές ανάγκες. Οι σχεσιακές βάσεις βασίζονται σε αυστηρά οργανωμένη δομή, με πίνακες και προκαθορισμένο σχήμα, προσφέροντας υψηλή συνέπεια και σαφή οργάνωση των δεδομένων. Αντίθετα, οι NoSQL βάσεις δίνουν μεγαλύτερη έμφαση στην ευελιξία, στην επεκτασιμότητα και στην ευκολότερη προσαρμογή της δομής των δεδομένων στις απαιτήσεις της εφαρμογής.

Η βασική διαφορά ανάμεσα στα δύο μοντέλα βρίσκεται στον τρόπο οργάνωσης και διαχείρισης της πληροφορίας. Στο σχεσιακό μοντέλο, τα δεδομένα οργανώνονται σε πίνακες και συνδέονται μεταξύ τους με σαφώς ορισμένο τρόπο. Στο NoSQL μοντέλο, και ειδικότερα στις βάσεις εγγράφων, η πληροφορία μπορεί να αποθηκεύεται με πιο ευέλικτο τρόπο μέσα στο ίδιο αντικείμενο, χωρίς να απαιτείται πάντοτε αυστηρή τήρηση προκαθορισμένου σχήματος. Η προσέγγιση αυτή μπορεί να διευκολύνει την αποθήκευση δεδομένων με πολλά περιγραφικά χαρακτηριστικά ή με συχνές μεταβολές στη δομή τους.

Επιπλέον οι σχεσιακές βάσεις είναι συνήθως πιο κατάλληλες όταν απαιτείται υψηλός βαθμός συνέπειας, σταθερή δομή και σαφής έλεγχος των δεδομένων. Από την άλλη πλευρά οι NoSQL βάσεις προτιμώνται συχνά όταν προέχουν η κλιμάκωση, η υψηλή διαθεσιμότητα και η ευελιξία στη διαχείριση μεγάλων ή ετερογενών συνόλων δεδομένων. Συνεπώς η επιλογή μεταξύ των δύο μοντέλων δεν είναι απόλυτη αλλά εξαρτάται από τις ανάγκες της εφαρμογής, τη φύση των δεδομένων και το είδος των ερωτημάτων που πρέπει να υποστηριχθούν.

**Μεθοδολογία**

Η μεθοδολογία που ακολουθήθηκε βασίζεται στη συγκριτική μελέτη δύο διαφορετικών συστημάτων βάσεων δεδομένων, μίας σχεσιακής και μίας NoSQL, πάνω στο ίδιο πραγματικό σύνολο δεδομένων. Στόχος είναι να αξιολογηθεί στην πράξη ο τρόπος με τον οποίο τα δύο μοντέλα αποθηκεύουν, οργανώνουν και ανακτούν την ίδια πληροφορία, καθώς και η συμπεριφορά τους κατά την εκτέλεση κοινών ερωτημάτων. Για τον σκοπό αυτό, επιλέχθηκε ως σχεσιακή βάση η SQLite και ως NoSQL βάση η MongoDB, ενώ ως κοινό σύνολο δεδομένων χρησιμοποιείται υποσύνολο πραγματικών δεδομένων ταινιών από το IMDb.

Σε πρώτο στάδιο, τα αρχεία του IMDb θα υποστούν προεπεξεργασία ώστε να διατηρηθούν μόνο τα δεδομένα που είναι απαραίτητα για τη μελέτη. Ειδικότερα, θα γίνει επιλογή μόνο των εγγραφών που αντιστοιχούν σε κινηματογραφικές ταινίες (titleType = movie), ενώ από τα διαθέσιμα πεδία θα διατηρηθούν εκείνα που σχετίζονται με την ταυτότητα της ταινίας, τον τίτλο, το έτος κυκλοφορίας, τη διάρκεια, τα είδη, τη μέση βαθμολογία, τον αριθμό ψήφων, τους βασικούς ηθοποιούς και τους σκηνοθέτες. Η διαδικασία αυτή είναι απαραίτητη ώστε το τελικό σύνολο δεδομένων να είναι καθαρό, ομοιογενές και κατάλληλο για αξιόπιστη σύγκριση.

Στη συνέχεια, τα ίδια δεδομένα θα εισαχθούν και στα δύο συστήματα βάσεων δεδομένων, με διαφορετικό όμως τρόπο μοντελοποίησης. Στην SQLite τα δεδομένα θα οργανωθούν σε πίνακες με σαφώς ορισμένα πεδία και σχέσεις, σύμφωνα με τη λογική του σχεσιακού μοντέλου. Αντίστοιχα στη MongoDB τα δεδομένα θα αποθηκευτούν σε συλλογές εγγράφων, ακολουθώντας τη λογική των βάσεων εγγράφων. Με αυτόν τον τρόπο καθίσταται δυνατή η άμεση σύγκριση των δύο προσεγγίσεων πάνω στην ίδια πληροφορία.

Για την πειραματική αξιολόγηση θα χρησιμοποιηθεί κοινό σύνολο ερωτημάτων και στις δύο βάσεις. Τα ερωτήματα αυτά θα περιλαμβάνουν αναζητήσεις ταινιών ανά είδος, ανά έτος κυκλοφορίας και ανά εύρος βαθμολογίας, καθώς και συγκεντρωτικά ερωτήματα, όπως το πλήθος ταινιών ανά είδος και ο μέσος όρος βαθμολογίας ανά είδος. Επιπλέον, με την ενσωμάτωση των βασικών ηθοποιών και των σκηνοθετών θα είναι δυνατή και η εκτέλεση σύνθετων αναζητήσεων, όπως η ανάκτηση ταινιών συγκεκριμένου ηθοποιού, η ανάκτηση ταινιών συγκεκριμένου σκηνοθέτη και η σύγκριση έργων με βάση τη συμμετοχή ηθοποιών ή τη σκηνοθεσία. Τα ίδια ερωτήματα θα υλοποιηθούν και στα δύο συστήματα, ώστε να συγκριθούν τόσο η λογική διατύπωσής τους όσο και η βασική τους απόδοση.

Η αξιολόγηση των αποτελεσμάτων θα βασιστεί κυρίως σε τέσσερις άξονες: στη δομή αποθήκευσης των δεδομένων, στην ευκολία μοντελοποίησης, στη σαφήνεια και πολυπλοκότητα των ερωτημάτων και στη βασική απόδοση κατά την εκτέλεσή τους. Τα αποτελέσματα θα παρουσιαστούν με πίνακες και γραφήματα, ώστε να είναι δυνατή η πιο καθαρή αποτύπωση των διαφορών ανάμεσα στο σχεσιακό και στο NoSQL μοντέλο.

## Υλοποίηση της σχεσιακής βάσης δεδομένων SQLite

### Δομή και σχεδίαση της βάσης SQLite

Η σχεδίαση της σχεσιακής βάσης δεδομένων πραγματοποιήθηκε με στόχο την οργανωμένη αποθήκευση των πληροφοριών που προέκυψαν από το υποσύνολο δεδομένων του IMDb καθώς και την υποστήριξη ερωτημάτων που αφορούν ταινίες, ηθοποιούς και σκηνοθέτες. Για την υλοποίηση της βάσης επιλέχθηκε η SQLite ενώ η δομή της βασίστηκε στη λογική του σχεσιακού μοντέλου, σύμφωνα με το οποίο τα δεδομένα αποθηκεύονται σε πίνακες με σαφώς ορισμένα πεδία και σχέσεις μεταξύ τους. Η επιλογή αυτή κρίθηκε κατάλληλη καθώς το σύνολο δεδομένων της εργασίας περιλαμβάνει διαφορετικές αλλά συσχετιζόμενες οντότητες, οι οποίες μπορούν να οργανωθούν αποτελεσματικά σε ξεχωριστούς πίνακες.

Η τελική βάση αποτελείται από πέντε βασικούς πίνακες. Ο πρώτος πίνακας, movies, περιλαμβάνει τα κύρια χαρακτηριστικά κάθε ταινίας, όπως το μοναδικό αναγνωριστικό tconst, τον βασικό και τον πρωτότυπο τίτλο, την ένδειξη καταλληλότητας για ενήλικο κοινό, το έτος κυκλοφορίας, τη διάρκεια, τα είδη της ταινίας, τη μέση βαθμολογία και τον αριθμό ψήφων. Ο πίνακας αυτός αποτελεί τον κεντρικό πυρήνα της βάσης, καθώς γύρω από αυτόν οργανώνονται οι υπόλοιπες πληροφορίες.

Ο δεύτερος πίνακας, actors, αποθηκεύει τα βασικά στοιχεία των ηθοποιών και συγκεκριμένα το μοναδικό αναγνωριστικό nconst και το όνομα primaryName. Ο τρίτος πίνακας, movie_actors, λειτουργεί ως πίνακας συσχέτισης μεταξύ ταινιών και ηθοποιών και περιλαμβάνει το αναγνωριστικό της ταινίας, το αναγνωριστικό του ηθοποιού, τη σειρά εμφάνισης (ordering_num) και την κατηγορία συμμετοχής (category). Με τον τρόπο αυτό αποτυπώνεται σωστά το γεγονός ότι μία ταινία μπορεί να συνδέεται με περισσότερους από έναν ηθοποιούς, ενώ ένας ηθοποιός μπορεί να συμμετέχει σε πολλές διαφορετικές ταινίες.

Αντίστοιχα, για τους σκηνοθέτες δημιουργήθηκαν οι πίνακες directors και movie_directors. Ο πίνακας directors περιλαμβάνει το μοναδικό αναγνωριστικό nconst και το όνομα primaryName κάθε σκηνοθέτη, ενώ ο πίνακας movie_directors χρησιμοποιείται για τη σύνδεση των σκηνοθετών με τις ταινίες που έχουν σκηνοθετήσει. Και στην περίπτωση αυτή, μία ταινία μπορεί να συνδέεται με περισσότερους από έναν σκηνοθέτες, ενώ ένας σκηνοθέτης μπορεί

να συνδέεται με πολλές ταινίες. Η διάσπαση αυτή σε ξεχωριστούς πίνακες εξασφαλίζει καλύτερη οργάνωση, μειώνει τον πλεονασμό και διευκολύνει την εκτέλεση πιο σύνθετων ερωτημάτων.

Κατά τη δημιουργία της βάσης ορίστηκαν πρωτεύοντα κλειδιά στους βασικούς πίνακες (tconst για τις ταινίες και nconst για τα πρόσωπα), ενώ οι πίνακες συσχέτισης περιλαμβάνουν πεδία που συνδέουν τις ταινίες με τους αντίστοιχους ηθοποιούς και σκηνοθέτες. Επιπλέον, δημιουργήθηκαν κατάλληλα ευρετήρια (indexes) σε πεδία όπως το έτος κυκλοφορίας, η βαθμολογία, ο αριθμός ψήφων και τα ονόματα προσώπων, ώστε να βελτιωθεί η απόδοση των αναζητήσεων. Η δομή αυτή θεωρείται κατάλληλη για τη σχεσιακή αναπαράσταση του επιλεγμένου συνόλου δεδομένων, καθώς υποστηρίζει τόσο απλά όσο και πιο σύνθετα ερωτήματα, διατηρώντας παράλληλα σαφήνεια και οργανωμένη δομή των δεδομένων.

**Εισαγωγή και οργάνωση των δεδομένων - SQLite**

Η εισαγωγή και η οργάνωση των δεδομένων αποτέλεσαν βασικό στάδιο της εργασίας, καθώς το αρχικό σύνολο δεδομένων του IMDb δεν ήταν έτοιμο να χρησιμοποιηθεί αυτούσιο στη σχεσιακή βάση. Για τον λόγο αυτό, έγινε αρχικά επεξεργασία των δεδομένων, με στόχο την επιλογή μόνο των απαραίτητων αρχείων και πεδίων, ώστε να δημιουργηθεί ένα καθαρό και κατάλληλα οργανωμένο υποσύνολο δεδομένων για τη μελέτη. Η διαδικασία αυτή πραγματοποιήθηκε προγραμματιστικά με χρήση Python, γεγονός που επέτρεψε την αυτοματοποιημένη διαχείριση των αρχείων και τη μείωση πιθανών λαθών κατά την επεξεργασία.

Από το αρχικό σύνολο δεδομένων του IMDb επιλέχθηκαν τα αρχεία title.basics.tsv.gz, title.ratings.tsv.gz, title.principals.tsv.gz, title.crew.tsv.gz και name.basics.tsv.gz. Αρχικά διατηρήθηκαν μόνο οι εγγραφές που αντιστοιχούσαν σε κινηματογραφικές ταινίες, δηλαδή όσες είχαν τιμή titleType = movie. Στη συνέχεια, από τα διαθέσιμα πεδία κρατήθηκαν μόνο όσα κρίθηκαν απαραίτητα για τους στόχους της εργασίας, όπως ο τίτλος, το έτος κυκλοφορίας, η διάρκεια, τα είδη, η μέση βαθμολογία, ο αριθμός ψήφων, οι βασικοί ηθοποιοί και οι σκηνοθέτες. Με τον τρόπο αυτό δημιουργήθηκε ένα υποσύνολο δεδομένων πιο ομοιογενές και περισσότερο προσαρμοσμένο στις ανάγκες της συγκριτικής μελέτης.

Μετά την επεξεργασία των δεδομένων δημιουργήθηκαν πέντε καθαρά αρχεία CSV, τα οποία αποτέλεσαν την ενδιάμεση μορφή των δεδομένων πριν από την εισαγωγή τους στη βάση SQLite. Συγκεκριμένα, το αρχείο movies.csv περιλάμβανε τα βασικά χαρακτηριστικά κάθε

ταινίας, το actors.csv τα βασικά στοιχεία των ηθοποιών, το movie_actors.csv τις συνδέσεις μεταξύ ταινιών και ηθοποιών, το directors.csv τα στοιχεία των σκηνοθετών και το movie_directors.csv τις συνδέσεις μεταξύ ταινιών και σκηνοθετών. Η διάσπαση αυτή των δεδομένων σε επιμέρους αρχεία διευκόλυνε την οργανωμένη εισαγωγή τους στη βάση και ήταν συμβατή με τον σχεσιακό τρόπο μοντελοποίησης που ακολουθήθηκε στην εργασία.

Μετά τη δημιουργία των καθαρών αρχείων πραγματοποιήθηκε η εισαγωγή τους στη βάση SQLite μέσω ειδικού προγράμματος σε Python. Το πρόγραμμα αυτό δημιούργησε τη βάση δεδομένων, όρισε τη δομή των πινάκων και φόρτωσε σε αυτούς τις εγγραφές από τα αντίστοιχα αρχεία CSV. Παράλληλα, δημιουργήθηκαν κατάλληλα ευρετήρια σε βασικά πεδία, όπως το έτος κυκλοφορίας, η βαθμολογία, ο αριθμός ψήφων και τα ονόματα των προσώπων, ώστε να διευκολυνθεί η ταχύτερη αναζήτηση και εκτέλεση ερωτημάτων. Με τον τρόπο αυτό τα αρχικά δεδομένα του IMDb μετατράπηκαν σε μία πλήρως λειτουργική σχεσιακή βάση δεδομένων, κατάλληλη για το πειραματικό μέρος της εργασίας.

Μετά την ολοκλήρωση της δημιουργίας της βάσης SQLite, πραγματοποιήθηκε βασικός έλεγχος ορθής λειτουργίας με δοκιμαστικά ερωτήματα, ώστε να επιβεβαιωθεί ότι οι πίνακες είχαν δημιουργηθεί σωστά και ότι οι συνδέσεις μεταξύ ταινιών, ηθοποιών και σκηνοθετών λειτουργούσαν όπως αναμενόταν. Ειδικότερα, ελέγχθηκαν περιπτώσεις αναζήτησης ταινιών συγκεκριμένου σκηνοθέτη, καθώς και ταινιών συγκεκριμένου ηθοποιού σε συνδυασμό με φίλτρα ως προς το είδος. Ο έλεγχος αυτός χρησιμοποιήθηκε για να επιβεβαιωθεί η ορθή οργάνωση των δεδομένων και η σωστή λειτουργία της βάσης πριν από την εκτέλεση των κύριων ερωτημάτων της εργασίας.

## Υλοποίηση της NoSQL βάσης MongoDB

### Δομή και σχεδίαση της βάσης MongoDB

Η σχεδίαση της NoSQL βάσης δεδομένων πραγματοποιήθηκε με στόχο την αποθήκευση του ίδιου συνόλου πληροφοριών που χρησιμοποιήθηκε και στη σχεσιακή βάση, αλλά με διαφορετικό τρόπο οργάνωσης, σύμφωνα με τη λογική των βάσεων εγγράφων. Για την υλοποίηση της βάσης επιλέχθηκε η MongoDB επειδή αποτελεί ένα ευρέως χρησιμοποιούμενο σύστημα διαχείρισης μη σχεσιακών δεδομένων και είναι κατάλληλη για την αποθήκευση σύνθετων πληροφοριών σε μορφή εγγράφων. Η επιλογή αυτή κρίθηκε κατάλληλη για τη συγκεκριμένη

εργασία επειδή τα δεδομένα των ταινιών περιλαμβάνουν όχι μόνο βασικά χαρακτηριστικά, όπως τίτλο, έτος, είδος και βαθμολογία, αλλά και πληροφορίες που σχετίζονται με πρόσωπα, όπως οι ηθοποιοί και οι σκηνοθέτες.

Σε αντίθεση με τη σχεσιακή βάση SQLite, όπου τα δεδομένα αποθηκεύτηκαν σε ξεχωριστούς πίνακες και οι ταινίες συσχετίστηκαν με τους ηθοποιούς και τους σκηνοθέτες τους, στη MongoDB η πληροφορία οργανώθηκε σε συλλογές εγγράφων. Η κύρια συλλογή της βάσης είναι η movies, στην οποία κάθε έγγραφο αντιστοιχεί σε μία ταινία και περιλαμβάνει τα βασικά χαρακτηριστικά της, όπως το αναγνωριστικό tconst, τον βασικό και τον πρωτότυπο τίτλο, την ένδειξη καταλληλότητας για ενήλικο κοινό, το έτος κυκλοφορίας, τη διάρκεια, τα είδη, τη μέση βαθμολογία και τον αριθμό ψήφων. Με τον τρόπο αυτό κάθε ταινία αποθηκεύεται ως ενιαίο αντικείμενο, το οποίο συγκεντρώνει σε ένα σημείο τις βασικές πληροφορίες που τη χαρακτηρίζουν.

Επιπλέον, μέσα στο ίδιο έγγραφο της ταινίας ενσωματώθηκαν και πληροφορίες για τους βασικούς ηθοποιούς και τους σκηνοθέτες. Πιο συγκεκριμένα, σε κάθε έγγραφο της συλλογής movies δημιουργήθηκαν πεδία τύπου λίστας για τους actors και τους directors, ώστε να αποθηκεύονται μαζί με την ταινία τα πρόσωπα που συνδέονται με αυτή. Για τους ηθοποιούς διατηρήθηκαν στοιχεία όπως το αναγνωριστικό nconst, το όνομα, η σειρά εμφάνισης και η κατηγορία συμμετοχής, ενώ για τους σκηνοθέτες διατηρήθηκαν το αναγνωριστικό και το όνομα. Η επιλογή αυτή ακολουθεί τη λογική της MongoDB, σύμφωνα με την οποία σχετικές πληροφορίες μπορούν να αποθηκεύονται μέσα στο ίδιο έγγραφο, χωρίς να απαιτείται συνεχής αναζήτηση σε ξεχωριστές δομές.

Παράλληλα, δημιουργήθηκαν και οι συλλογές actors και directors, στις οποίες αποθηκεύτηκαν ξεχωριστά τα βασικά στοιχεία των προσώπων. Οι συλλογές αυτές δεν αποτελούν το κύριο σημείο εκτέλεσης των ερωτημάτων της εργασίας, αλλά χρησιμοποιούνται συμπληρωματικά, ώστε να υπάρχει πιο καθαρή οργάνωση των δεδομένων και δυνατότητα ανεξάρτητης πρόσβασης στα στοιχεία ηθοποιών και σκηνοθετών. Έτσι η βάση συνδυάζει δύο επίπεδα οργάνωσης: από τη μία πλευρά τα έγγραφα των ταινιών και από την άλλη πλευρά τις επιμέρους συλλογές προσώπων.

Κατά τη δημιουργία της βάσης ορίστηκαν επίσης ευρετήρια σε βασικά πεδία, όπως ο τίτλος, το έτος κυκλοφορίας, η βαθμολογία, ο αριθμός ψήφων, τα είδη της ταινίας, καθώς και τα

ονόματα των ηθοποιών και των σκηνοθετών. Η δομή αυτή κρίθηκε κατάλληλη για τη βάση MongoDB της εργασίας, καθώς επιτρέπει την αποθήκευση του ίδιου περιεχομένου με πιο ευέλικτο τρόπο και υποστηρίζει ερωτήματα που βασίζονται τόσο στα χαρακτηριστικά των ταινιών όσο και στα πρόσωπα που συνδέονται με αυτές.

**Εισαγωγή και οργάνωση των δεδομένων – MongoDB**

Η εισαγωγή και η οργάνωση των δεδομένων στη MongoDB βασίστηκαν στο ίδιο καθαρό σύνολο αρχείων που είχε ήδη προκύψει από την αρχική επεξεργασία των δεδομένων του IMDb. Με τον τρόπο αυτό διασφαλίστηκε ότι η MongoDB και η SQLite χρησιμοποιούν ακριβώς το ίδιο πληροφοριακό περιεχόμενο, ώστε η σύγκριση των δύο βάσεων να είναι ουσιαστική και δίκαιη. Για τον σκοπό αυτό αξιοποιήθηκαν τα αρχεία movies.csv, actors.csv, movie_actors.csv, directors.csv και movie_directors.csv, τα οποία περιλάμβαναν τις τελικές καθαρές εγγραφές για τις ταινίες, τους ηθοποιούς, τους σκηνοθέτες και τις αντίστοιχες συσχετίσεις τους.

Η εισαγωγή των δεδομένων πραγματοποιήθηκε προγραμματιστικά με χρήση Python και του εργαλείου σύνδεσης PyMongo, το οποίο επέτρεψε την επικοινωνία με τον τοπικό MongoDB server. Κατά τη διαδικασία αυτή δημιουργήθηκε η βάση imdb_mongodb_db και οργανώθηκαν τα δεδομένα σε τρεις βασικές συλλογές, τις movies, actors και directors. Στις συλλογές actors και directors αποθηκεύτηκαν τα βασικά στοιχεία των προσώπων, ενώ στη συλλογή movies αποθηκεύτηκαν τα πλήρη έγγραφα των ταινιών, εμπλουτισμένα με τις πληροφορίες που αφορούσαν τους ηθοποιούς και τους σκηνοθέτες κάθε ταινίας.

Συγκεκριμένα κατά την κατασκευή των εγγράφων της συλλογής movies, για κάθε ταινία συγκεντρώθηκαν σε ένα ενιαίο αντικείμενο τα γενικά χαρακτηριστικά της, όπως ο τίτλος, το έτος κυκλοφορίας, η διάρκεια, τα είδη, η μέση βαθμολογία και ο αριθμός ψήφων, και στη συνέχεια ενσωματώθηκαν στο ίδιο έγγραφο οι λίστες των βασικών ηθοποιών και των σκηνοθετών. Η επιλογή αυτή επέτρεψε την αποθήκευση των σχετικών πληροφοριών μαζί με την ταινία, κάτι που είναι περισσότερο συμβατό με τη λογική των βάσεων εγγράφων και διευκολύνει την αναζήτηση με βάση σύνθετα χαρακτηριστικά.

Μετά την εισαγωγή των δεδομένων δημιουργήθηκαν ευρετήρια σε πεδία που κρίθηκαν σημαντικά για την εκτέλεση των ερωτημάτων της εργασίας, όπως ο τίτλος, το έτος κυκλοφορίας, η βαθμολογία, ο αριθμός ψήφων, τα είδη, καθώς και τα ονόματα των ηθοποιών και των

σκηνοθετών. Παράλληλα, πραγματοποιήθηκε βασικός έλεγχος της ορθής λειτουργίας της βάσης, ώστε να επιβεβαιωθεί ότι η βάση είχε δημιουργηθεί σωστά, ότι οι συλλογές περιείχαν τις αναμενόμενες εγγραφές και ότι τα δεδομένα των ταινιών, των ηθοποιών και των σκηνοθετών είχαν οργανωθεί ορθά πριν από την εκτέλεση των κύριων ερωτημάτων της εργασίας.

## Αξιολόγηση και πειραματικές μετρήσεις

Ο ορισμός των ερωτημάτων αξιολόγησης έγινε με στόχο την ουσιαστική σύγκριση της SQLite και της MongoDB ως προς διαφορετικά είδη αναζήτησης και επεξεργασίας δεδομένων.

### Ορισμός των ερωτημάτων αξιολόγησης

Για την πειραματική αξιολόγηση των δύο βάσεων δεδομένων επιλέχθηκε κοινό σύνολο επτά ερωτημάτων, ώστε η σύγκριση να βασιστεί ακριβώς στο ίδιο πληροφοριακό περιεχόμενο και στις ίδιες απαιτήσεις αναζήτησης. Τα ερωτήματα αυτά επιλέχθηκαν έτσι ώστε να καλύπτουν τόσο απλές αναζητήσεις όσο και πιο σύνθετες περιπτώσεις φιλτραρίσματος και συγκεντρωτικής επεξεργασίας δεδομένων. Πιο συγκεκριμένα χρησιμοποιήθηκαν τα ακόλουθα ερωτήματα:

1. Ανάκτηση όλων των ταινιών που ανήκουν στο είδος Comedy.
2. Ανάκτηση όλων των ταινιών που κυκλοφόρησαν από το 2000 έως το 2010.
3. Ανάκτηση ταινιών με βαθμολογία μεγαλύτερη από 8.0 και με περισσότερους από 100000 ψήφους.
4. Ανάκτηση ταινιών στις οποίες συμμετέχει ο Robert Pattinson και οι οποίες ανήκουν στο είδος Romance.
5. Ανάκτηση ταινιών του James Cameron που κυκλοφόρησαν μετά το 1990.
6. Υπολογισμός του πλήθους των ταινιών ανά είδος.
7. Υπολογισμός του μέσου όρου βαθμολογίας ανά είδος.

Τα παραπάνω ερωτήματα υλοποιήθηκαν και εκτελέστηκαν τόσο στη SQLite όσο και στη MongoDB και αποτέλεσαν τη βάση της πειραματικής σύγκρισης των δύο συστημάτων.

### Υλοποίηση των ερωτημάτων στη SQLite

Η υλοποίηση των ερωτημάτων στη SQLite βασίστηκε στη δομή της σχεσιακής βάσης που είχε ήδη δημιουργηθεί από τα αρχεία του IMDb. Η βάση περιλάμβανε ξεχωριστούς πίνακες για

τις ταινίες, τους ηθοποιούς, τους σκηνοθέτες και τις μεταξύ τους συνδέσεις, γεγονός που επέτρεψε την εκτέλεση ερωτημάτων με χρήση της γλώσσας SQL, δηλαδή της βασικής γλώσσας ερωτημάτων των σχεσιακών βάσεων δεδομένων. Στο πλαίσιο αυτό, τα απλά ερωτήματα, όπως η αναζήτηση ταινιών συγκεκριμένου είδους ή συγκεκριμένης χρονικής περιόδου, μπορούσαν να εκφραστούν απευθείας πάνω στον πίνακα των ταινιών, με χρήση κατάλληλων κριτηρίων στα αντίστοιχα πεδία.

Αντίθετα, τα πιο σύνθετα ερωτήματα απαιτούσαν συνδυασμό περισσότερων από έναν πινάκων. Για παράδειγμα, η αναζήτηση ταινιών συγκεκριμένου ηθοποιού ή συγκεκριμένου σκηνοθέτη στηρίχθηκε στη σύνδεση του πίνακα movies με τους πίνακες movie_actors, actors, movie_directors και directors. Με τον τρόπο αυτό έγινε δυνατή η ανάκτηση πληροφοριών όχι μόνο με βάση τα βασικά χαρακτηριστικά της ταινίας, αλλά και με βάση τα πρόσωπα που συνδέονται με αυτή. Η σχεσιακή δομή της SQLite εξυπηρέτησε αποτελεσματικά αυτού του είδους τις αναζητήσεις, αν και σε αρκετές περιπτώσεις η διατύπωση των ερωτημάτων απαιτούσε μεγαλύτερη συντακτική λεπτομέρεια, λόγω της ανάγκης σύνδεσης πολλών πινάκων.

Ιδιαίτερο ενδιαφέρον παρουσίασαν τα συγκεντρωτικά ερωτήματα, όπως το πλήθος ταινιών ανά είδος και ο μέσος όρος βαθμολογίας ανά είδος. Στην περίπτωση αυτή αξιοποιήθηκαν οι δυνατότητες της SQL για ομαδοποίηση και υπολογισμό συνοπτικών μεγεθών, γεγονός που επέτρεψε την εξαγωγή αποτελεσμάτων κατάλληλων για τη συγκριτική αξιολόγηση των δύο βάσεων. Τα ερωτήματα αυτά είναι σημαντικά, επειδή δεν περιορίζονται σε απλή ανάκτηση εγγραφών, αλλά επιτρέπουν τη μελέτη της συμπεριφοράς της βάσης σε πιο σύνθετες μορφές επεξεργασίας δεδομένων.

Η εκτέλεση των ερωτημάτων στη SQLite πραγματοποιήθηκε προγραμματιστικά μέσω Python, με σύνδεση στη βάση movies_sqlite.db. Με τον τρόπο αυτό, η SQLite αποτέλεσε το σημείο αναφοράς της σχεσιακής υλοποίησης για την τελική σύγκριση με τη NoSQL προσέγγιση.

**Υλοποίηση των ερωτημάτων στη MongoDB**

Η υλοποίηση των ερωτημάτων στη MongoDB βασίστηκε στη δομή της NoSQL βάσης που είχε ήδη δημιουργηθεί από το ίδιο σύνολο δεδομένων του IMDb. Σε αντίθεση με τη SQLite, όπου οι πληροφορίες ήταν κατανεμημένες σε ξεχωριστούς πίνακες, στη MongoDB το βασικό σημείο αναζήτησης ήταν η συλλογή movies, μέσα στην οποία κάθε έγγραφο περιλάμβανε όχι μόνο τα

κύρια χαρακτηριστικά της ταινίας, αλλά και ενσωματωμένες πληροφορίες για τους βασικούς ηθοποιούς και τους σκηνοθέτες. Η οργάνωση αυτή επέτρεψε την εκτέλεση πολλών ερωτημάτων πάνω στην ίδια συλλογή, χωρίς να απαιτείται σύνδεση πολλών διαφορετικών δομών, όπως συνέβαινε στη σχεσιακή βάση.

Τα απλά ερωτήματα, όπως η αναζήτηση ταινιών συγκεκριμένου είδους, συγκεκριμένης χρονικής περιόδου ή συγκεκριμένου εύρους βαθμολογίας, μπορούσαν να εκφραστούν άμεσα πάνω στα πεδία των εγγράφων της συλλογής movies. Επιπλέον, επειδή τα δεδομένα για τους ηθοποιούς και τους σκηνοθέτες ήταν ενσωματωμένα μέσα στην ίδια εγγραφή της ταινίας, έγινε δυνατή η διατύπωση πιο σύνθετων αναζητήσεων με βάση πρόσωπα και χαρακτηριστικά ταινιών, χωρίς να απαιτείται ξεχωριστή σύνδεση συλλογών για κάθε περίπτωση. Η ιδιαιτερότητα αυτή αποτελεί βασικό γνώρισμα της προσέγγισης των βάσεων εγγράφων και διαφοροποιεί ουσιαστικά τη MongoDB από τη λογική του σχεσιακού μοντέλου.

Ιδιαίτερο ενδιαφέρον παρουσίασαν και τα συγκεντρωτικά ερωτήματα στη MongoDB, καθώς η υλοποίησή τους βασίστηκε σε μηχανισμούς επεξεργασίας που διαφέρουν από τη λογική της SQL. Για ερωτήματα όπως το πλήθος ταινιών ανά είδος ή ο μέσος όρος βαθμολογίας ανά είδος αξιοποιήθηκε η δυνατότητα συγκεντρωτικής επεξεργασίας της MongoDB, η οποία επιτρέπει τη σταδιακή επεξεργασία των εγγράφων και την παραγωγή συνοπτικών αποτελεσμάτων. Με τον τρόπο αυτό η βάση δεν χρησιμοποιήθηκε μόνο για απλή αναζήτηση εγγραφών, αλλά και για πιο σύνθετη ανάλυση των δεδομένων.

Η εκτέλεση των ερωτημάτων στη MongoDB πραγματοποιήθηκε προγραμματιστικά μέσω Python, με χρήση του εργαλείου σύνδεσης PyMongo και σύνδεση στον τοπικό MongoDB server. Με τον τρόπο αυτό, η MongoDB αποτέλεσε τη NoSQL υλοποίηση της εργασίας, πάνω στην οποία βασίστηκε η τελική σύγκριση με τη SQLite.

**Σύγκριση αποτελεσμάτων και χρόνων εκτέλεσης**

Για την παρουσίαση των πειραματικών αποτελεσμάτων καταρτίστηκε συγκριτικός πίνακας, στον οποίο καταγράφονται για κάθε ερώτημα ο αριθμός των αποτελεσμάτων που επιστράφηκαν και ο μέσος χρόνος εκτέλεσης στη SQLite και στη MongoDB. Με τον τρόπο αυτό καθίσταται δυνατή η άμεση ποσοτική σύγκριση των δύο βάσεων πριν από τον αναλυτικό σχολιασμό των αποτελεσμάτων.

**Πίνακας 1. Συγκριτικά αποτελέσματα και μέσοι χρόνοι εκτέλεσης των ερωτημάτων στη SQLite και στη MongoDB.**

| Ερώτημα | Περιγραφή | SQLite (πλήθος) | SQLite (μ. χρόνος, s) | MongoDB (πλήθος) | MongoDB (μ. χρόνος, s) | Ταχύτερο σύστημα |
|---|---|---|---|---|---|---|
| **Q1** | Ταινίες είδους Comedy | 123670 | 0.235688 | 123670 | 0.365518 | SQLite |
| **Q2** | Ταινίες από το 2000 έως το 2010 | 91936 | 0.226662 | 91936 | 0.226428 | MongoDB |
| **Q3** | Βαθμολογία > 8.0 και ψήφοι > 100000 | 254 | 0.013272 | 254 | 0.010680 | MongoDB |
| **Q4** | Robert Pattinson και Romance | 5 | 0.000328 | 5 | 0.000937 | SQLite |
| **Q5** | James Cameron μετά το 1990 | 11 | 0.000190 | 11 | 0.000823 | SQLite |
| **Q6** | Πλήθος ταινιών ανά είδος | 27 | 1.235711 | 27 | 1.080262 | MongoDB |
| **Q7** | Μέσος όρος βαθμολογίας ανά είδος | 27 | 0.851257 | 27 | 1.038437 | SQLite |

Για την ευκολότερη οπτική σύγκριση των χρόνων εκτέλεσης, τα ίδια αποτελέσματα αποτυπώθηκαν και σε ραβδόγραμμα. Το διάγραμμα επιτρέπει την άμεση σύγκριση της επίδοσης των δύο βάσεων σε κάθε ερώτημα ξεχωριστά και διευκολύνει τον εντοπισμό των περιπτώσεων στις οποίες εμφανίζονται οι μεγαλύτερες διαφορές.

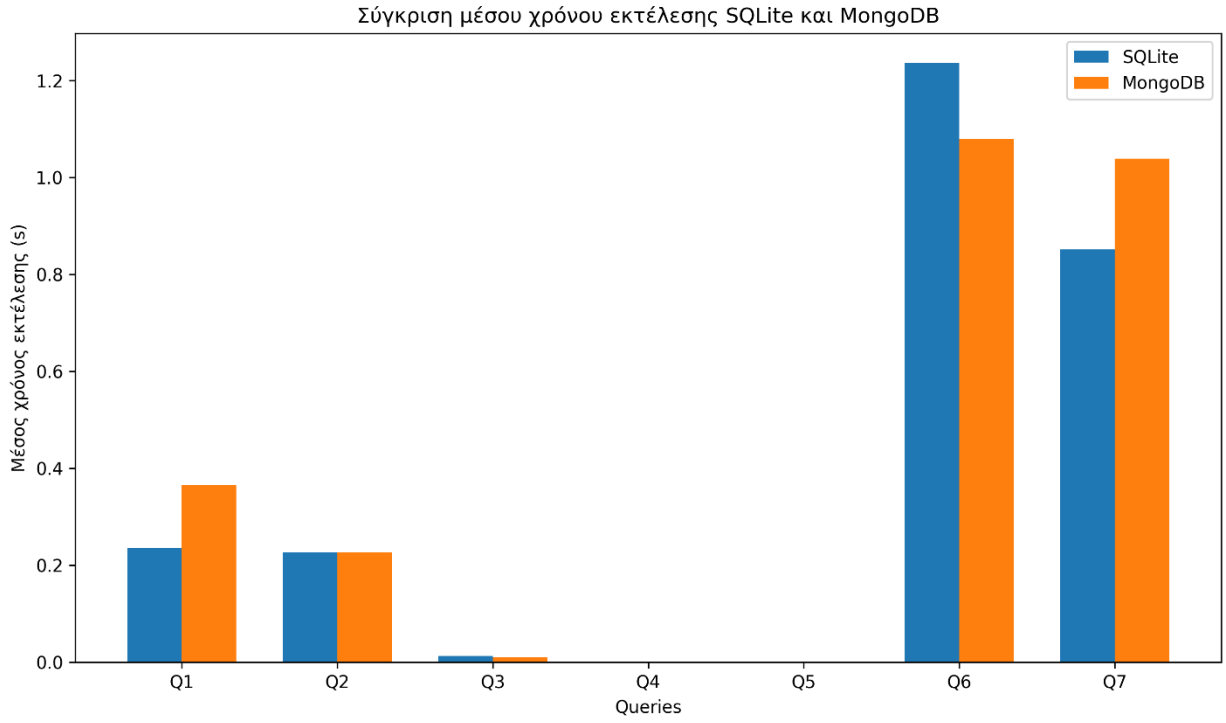


**Διάγραμμα I. Σύγκριση μέσου χρόνου εκτέλεσης των ερωτημάτων στη SQLite και στη MongoDB.**

Για την πληρέστερη αποτύπωση των διαφορών στα ερωτήματα με πολύ μικρούς χρόνους εκτέλεσης, παρατίθεται και δεύτερο διάγραμμα με εστίαση στα Q3, Q4 και Q5

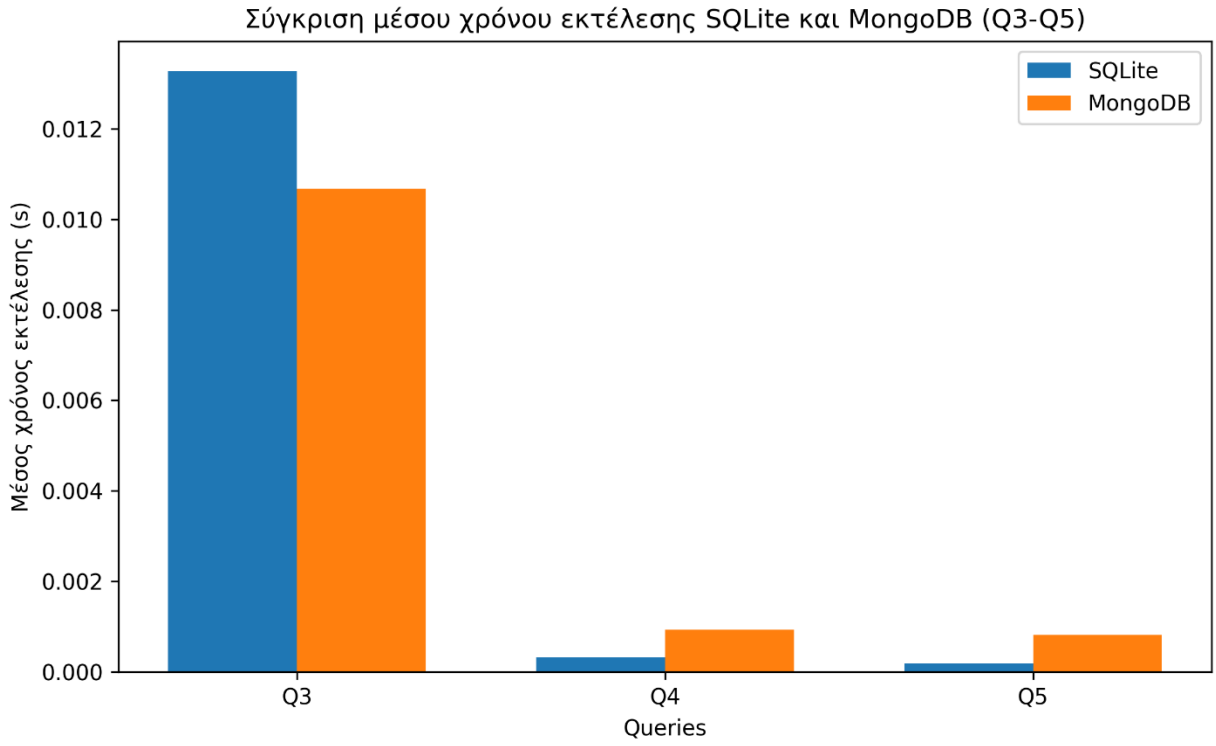


**Διάγραμμα II. Σύγκριση μέσου χρόνου εκτέλεσης SQLite και MongoDB (Q3–Q5)**

Η συγκριτική αξιολόγηση της SQLite και της MongoDB βασίστηκε στα επτά κοινά ερωτήματα που παρουσιάστηκαν προηγουμένως. Με βάση τα αποτελέσματα του πίνακα και του διαγράμματος, είναι δυνατό να συγκριθεί η συμπεριφορά των δύο βάσεων ως προς την ταχύτητα εκτέλεσης διαφορετικών κατηγοριών ερωτημάτων.

Από τα αποτελέσματα προέκυψε ότι και οι δύο βάσεις απέδωσαν σωστά τα ίδια δεδομένα στα αντίστοιχα ερωτήματα, γεγονός που δείχνει ότι η μοντελοποίηση και η εισαγωγή των δεδομένων πραγματοποιήθηκαν ορθά τόσο στη σχεσιακή όσο και στη NoSQL υλοποίηση. Ωστόσο οι χρόνοι εκτέλεσης δεν ήταν ίδιοι σε όλες τις περιπτώσεις. Σε ορισμένα ερωτήματα η

SQLite παρουσίασε καλύτερη απόδοση, ενώ σε άλλα η MongoDB αποδείχθηκε ταχύτερη. Το εύρημα αυτό δείχνει ότι η αποδοτικότητα κάθε βάσης εξαρτάται από τη φύση του ερωτήματος και από τον τρόπο με τον οποίο είναι οργανωμένα τα δεδομένα σε κάθε σύστημα.

Στα ερωτήματα απλής αναζήτησης, όπως η ανάκτηση ταινιών είδους Comedy, η SQLite εμφάνισε μικρότερο μέσο χρόνο εκτέλεσης από τη MongoDB. Επίσης, στα ερωτήματα που αφορούσαν πολύ συγκεκριμένες αναζητήσεις με βάση πρόσωπα, όπως οι ταινίες του Robert Pattinson με είδος Romance και οι ταινίες του James Cameron μετά το 1990, η SQLite αποδείχθηκε επίσης ταχύτερη. Οι διαφορές αυτές μπορούν να εξηγηθούν από το γεγονός ότι στη SQLite τα δεδομένα είναι οργανωμένα με σαφή σχεσιακό τρόπο και υποστηρίζονται από κατάλληλα ευρετήρια, γεγονός που ευνοεί στοχευμένα ερωτήματα μικρού εύρους.

Αντίθετα σε άλλα ερωτήματα η MongoDB παρουσίασε καλύτερη συμπεριφορά. Στην αναζήτηση ταινιών από το 2000 έως το 2010 η διαφορά ήταν μικρή αλλά υπέρ της MongoDB, ενώ και στο ερώτημα επιλογής ταινιών με βαθμολογία μεγαλύτερη από 8.0 και περισσότερους από 100000 ψήφους η MongoDB εμφάνισε ελαφρώς καλύτερο χρόνο. Ιδιαίτερο ενδιαφέρον παρουσίασε το συγκεντρωτικό ερώτημα για το πλήθος ταινιών ανά είδος, όπου η MongoDB ήταν αισθητά ταχύτερη από τη SQLite. Το αποτέλεσμα αυτό είναι λογικό, καθώς στη MongoDB τα είδη είχαν αποθηκευτεί εξαρχής σε μορφή λίστας μέσα στο έγγραφο κάθε ταινίας, ενώ στη SQLite ήταν αποθηκευμένα ως ενιαίο κείμενο και απαιτήθηκε επιπλέον επεξεργασία για τον διαχωρισμό τους πριν από την ομαδοποίηση.

Στο ερώτημα του μέσου όρου βαθμολογίας ανά είδος, η SQLite παρουσίασε καλύτερη επίδοση από τη MongoDB, γεγονός που δείχνει ότι η σχεσιακή προσέγγιση παραμένει ιδιαίτερα αποτελεσματική και σε συγκεντρωτικά ερωτήματα, όταν η βάση είναι καλά οργανωμένη και τα δεδομένα δεν ξεπερνούν τα όρια μιας τοπικής πειραματικής υλοποίησης. Επομένως, τα αποτελέσματα δεν υποστηρίζουν την άποψη ότι ένα από τα δύο συστήματα υπερέχει συνολικά σε κάθε περίπτωση. Αντίθετα, δείχνουν ότι η SQLite και η MongoDB εμφανίζουν διαφορετικά πλεονεκτήματα, ανάλογα με το είδος της αναζήτησης και τη μορφή με την οποία έχουν οργανωθεί τα δεδομένα.

Συνολικά, η SQLite αποδείχθηκε ιδιαίτερα αποτελεσματική σε στοχευμένα και συγκεκριμένα ερωτήματα, καθώς και σε ορισμένες περιπτώσεις συγκεντρωτικής επεξεργασίας, ενώ η MongoDB έδειξε πλεονέκτημα σε ερωτήματα που αξιοποιούν πιο φυσικά τη δομή

εγγράφων και την ενσωματωμένη αποθήκευση σύνθετων χαρακτηριστικών. Για τον λόγο αυτό, η παρούσα πειραματική μελέτη οδηγεί στο συμπέρασμα ότι η επιλογή ανάμεσα σε σχεσιακή και NoSQL βάση δεδομένων δεν πρέπει να γίνεται με απόλυτους όρους, αλλά με κριτήριο τη φύση των δεδομένων, τον τρόπο μοντελοποίησής τους και το είδος των ερωτημάτων που πρέπει να υποστηριχθούν.

## Βιβλιογραφία


1. Καναβός, Ανδρέας. *Μοντέρνες Βάσεις Δεδομένων*. Τμήμα Πληροφορικής, Ιόνιο Πανεπιστήμιο.
2. Καναβός, Ανδρέας. *Διαχείριση Δεδομένων Μεγάλης Κλίμακας (Big Data, MapReduce, Hadoop & NoSQL)*. Τμήμα Πληροφορικής, Ιόνιο Πανεπιστήμιο.
3. Vaish, Gaurav. *Getting Started with NoSQL: Your Guide to the World and Technology of NoSQL*. Packt Publishing, 2013.
4. IMDb. *IMDb Non-Commercial Datasets*. Χρησιμοποιήθηκε ως πηγή του συνόλου δεδομένων της εργασίας.